Biometrický systém na báze ľudskej tváre

Zadanie č.4

Biometria

Obsah

- Zadanie č.4
  - Inštrukcie
  - Model riešenia a základné pojmy
  - Bodovanie

Inštrukcie 1/2

- Znenie zadania:
  - Implementujte **dvoj-fázový** biometrický systém, ktorý rozpoznáva osobu pomocou obrazu tváre
  - Dvoj-fázový systém:

    Fáza č. 1 Extrakcia charakteristických znakov tváre pomocou PCA metódy

    Fáza č. 2 Klasifikácia extrahovaných znakov pomocou 3 techník

Inštrukcie 2/2

- Znenie zadania:
  - Klasifikačné techniky, ktoré bude váš softvér vykonávať:
    1. **SVM** (Support Vector Machine)
    2. **Euklidova** vzdialenosť
    3. **Mahalanobisova** vzdialenosť
  - Cieľom je porovnanie týchto klasifikačných techník pomocou **percentuálnej úspešnosti klasifikácie v závislosti od rastúceho počtu hlavných komponentov PCA**
  - Zvoľte si postupne zvyšujúci sa počet hlavných komponentov, napr. 1, 2 až 100)
  - Pre každú konfiguráciu PCA metódy vykonajte **aspoň 3 kolá cross-validácie**

Model riešenia a základné pojmy

- Databáza obrazov tváre A
  - Názov databázy je ***faces*** (nahraná v AIS)
  - Obsahuje 15 osôb (10 obrazov tváre/osoba)
  - Rozmery sú Š(92) x V(112)
  - Formát názvu *XX_YY*

ID osoby

ID fotky

Model riešenia a základné pojmy

- Databáza obrazov tváre B
  - Názov databázy je ***famous_faces*** (nahraná v AIS)
  - Obsahuje 6 známych osôb (12 obrazov tváre/osoba)
  - Rozmery sú Š(200) x V(250)
  - Formát názvu *XX_YY*

meno osoby

ID fotky

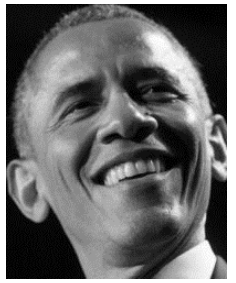
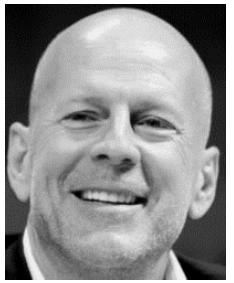
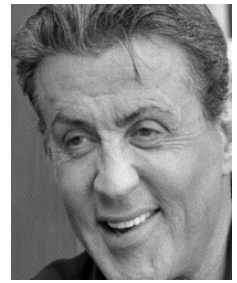
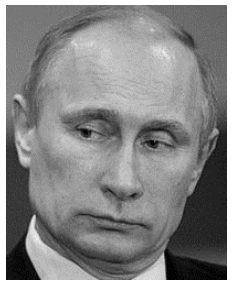

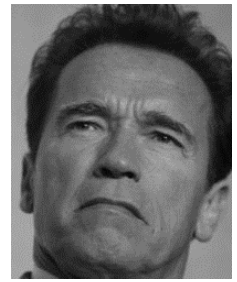

Model riešenia a základné pojmy

- Fáza č.1 – extrakcia znakov použitím PCA metódy
  - Použite dostupné implementácie PCA (napr. OpenCV, Matlab ...)
  - V zadaní si vytvorte konfiguráciu PCA modelu podľa počtu „eigenvektorov“ resp. hlavných komponentov

```
cv::PCA::PCA ( InputArray  data,
               InputArray  mean,
               int         flags,
               int         maxComponents = 0
             )
```

PCA v knižnici OpenCV

Model riešenia a základné pojmy

- Fáza č.1 – extrakcia znakov použitím PCA metódy
  - Pre každú konfiguráciu PCA modelu vykonajte aspoň 3 kolá cross-validácie

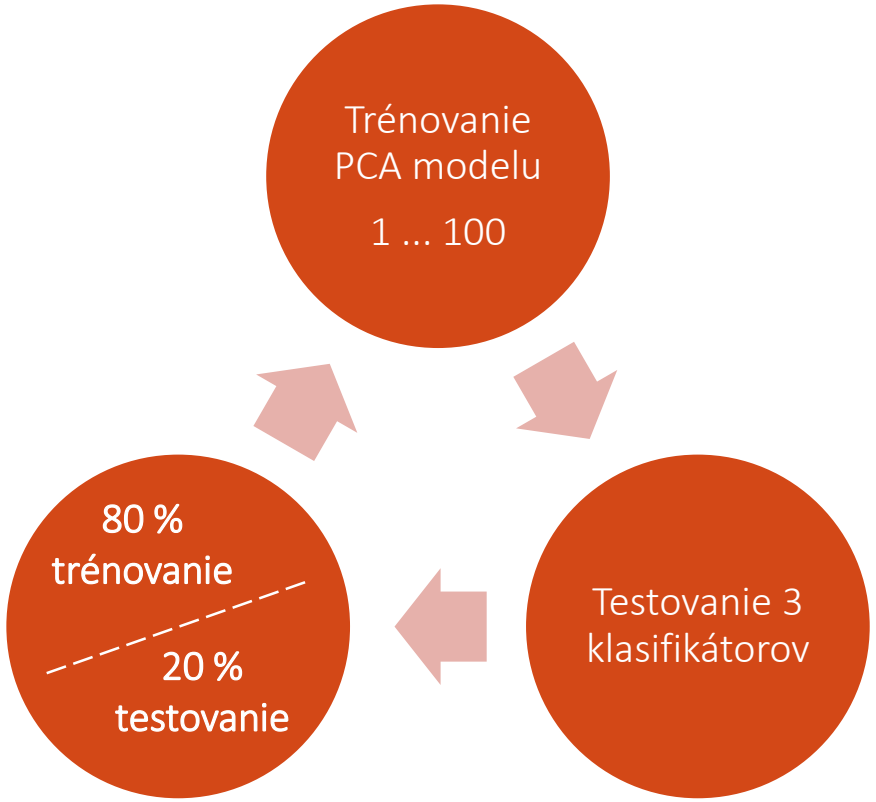

Cyklus zopakovať aspoň 3-krát

Model riešenia a základné pojmy

- Fáza č.2 – klasifikácia
  - **Klasifikujú sa PCA koeficienty získané po projekcii pôvodných údajov do PCA priestoru**
  - V prípade OpenCV je to vektor PCA koeficientov vrátený metódou *PCA::project()*
  - Klasifikujeme všetky obrazy tváre v testovacej množine

Model riešenia a základné pojmy

- Fáza č.2 – klasifikácia pomocou SVM
  - Použite **RBF ako kernel funkciu** (kernel = funkcia vyjadrujúca podobnosť 2 vzoriek v priestore vyššej dimenzie), **experimentujte s parametrom *SIGMA***
  - Vysvetlenie "kernel" triku vo forme animácie (http://y2u.be/BE1M1xxr03s)

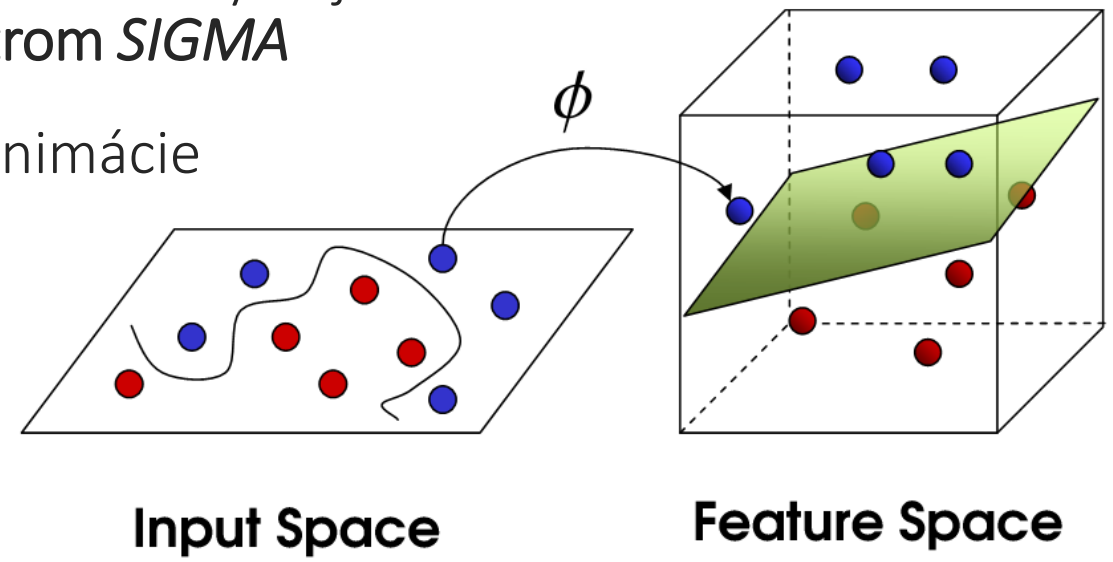

Model riešenia a základné pojmy

- Fáza č.2 – klasifikácia pomocou SVM

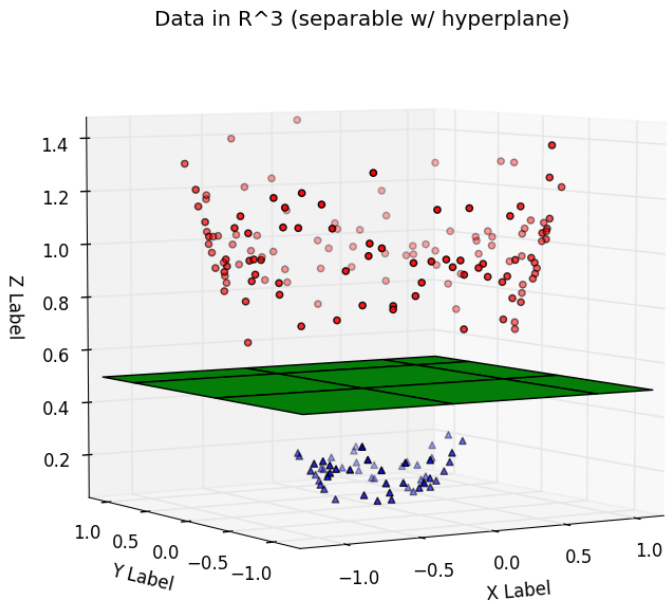

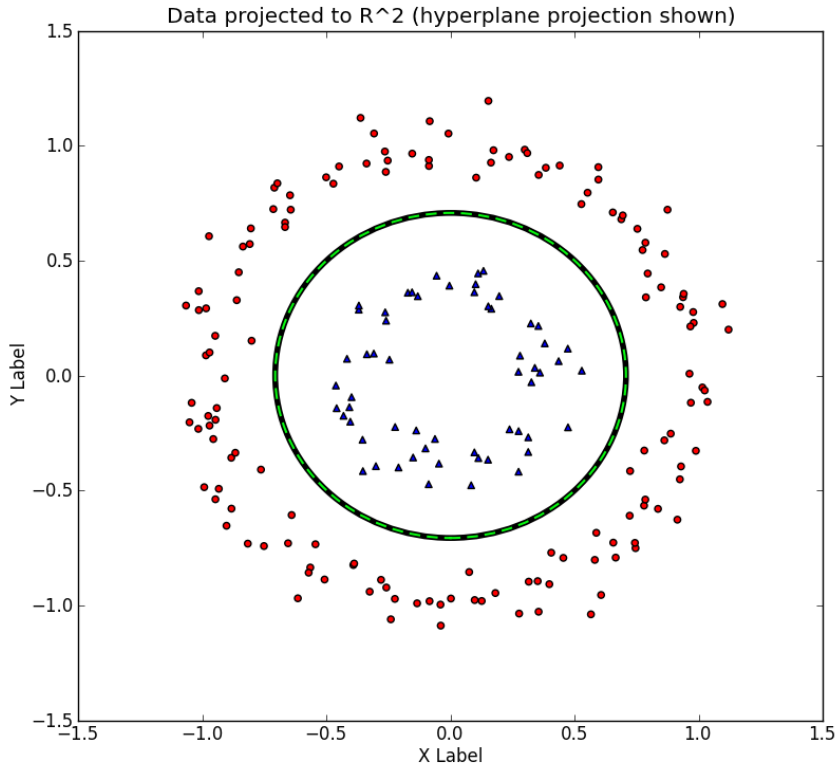

Model riešenia a základné pojmy

- Fáza č.2 – klasifikácia pomocou SVM
  - Snažíme sa vypočítať $K(x,y) = \Phi(x) \cdot \Phi(y)$, čo môže byť výpočtovo náročné
  - Príklad:
    - mapovanie je $\Phi(\mathrm{x}) = (\mathrm{x_1}^2, \sqrt{2}\mathrm{x_1}\mathrm{x_2}, \mathrm{x_2}^2)$
    - výpočtovo jednoduchší je tzv. „kernel trick“ vo forme $K(x,y) = (x \cdot y)^2$
    - Všeobecný polynomiálny kernel $K(x,y) = ((x \cdot y) + \theta)^d$
    - Všeobecný RBF kernel $K(x,y) = e^{-\frac{\|x-y\|^2}{2\sigma^2}}$

Model riešenia a základné pojmy

- Fáza č.2 – klasifikácia pomocou SVM
  - Implementácia SVM pre používateľov **Matlabu:**

    http://www.mathworks.com/matlabcentral/fileexchange/33170-multi-class-support-vector-machine (používa RBF ako kernel funkciu)

  - Implementácia SVM pre používateľov **OpenCV 3+ :**

    http://docs.opencv.org/3.1.0/d1/d2d/classcv_1_1ml_1_1SVM.html#gsc.tab=0

    http://docs.opencv.org/3.0-beta/modules/ml/doc/support_vector_machines.html

Model riešenia a základné pojmy

- Fáza č.2 – klasifikácia pomocou Euklidovej vzdialenosti
  - Porovnávame 2 vektory PCA koeficientov pomocou Euklidovej vzdialenosti
  - Pri identifikácii hľadáme v trénovacej databáze vektor s najmenšou Euklidovou vzdialenosťou od neznámeho testovacieho vektora
  - Euklidovu vzdialenosť vektorov x a y vypočítame nasledovne:

$$d(x,y) = \sqrt{(x_1 - y_1)^2 + (x_2 - y_2)^2 + \ \ldots + (x_n - y_n)^2}$$

Model riešenia a základné pojmy

- Fáza č.2 – klasifikácia pomocou Mahalanobisovej vzdialenosti
  - Je to forma vyjadrenia vzdialenosti vektora x od stredu pravdepodobnostného rozdelenia P
  - Meria sa počet štandardných odchýlok medzi x a P

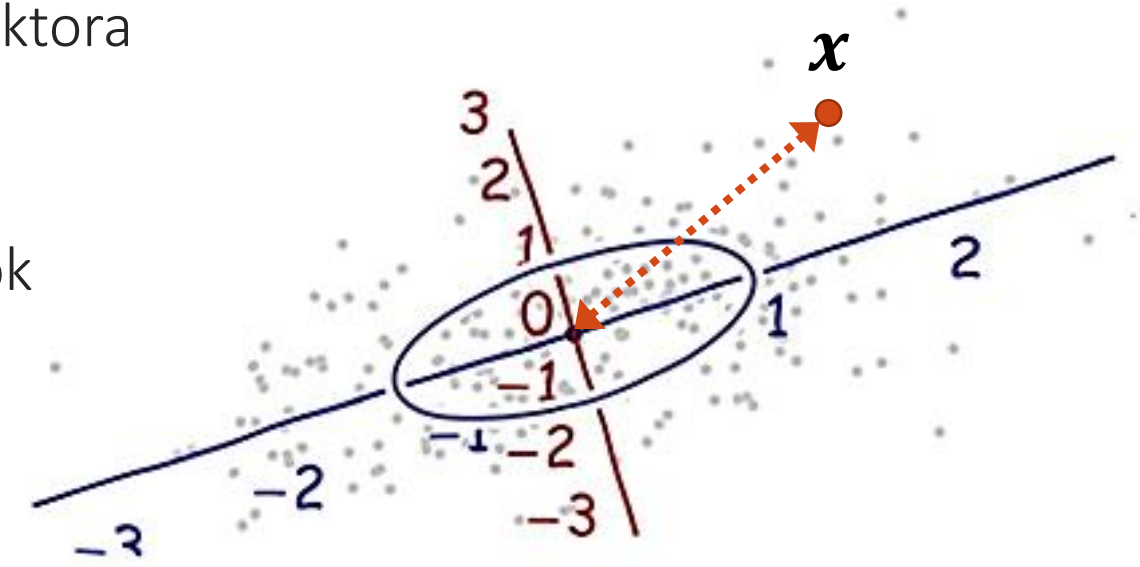

Model riešenia a základné pojmy

- Fáza č.2 – klasifikácia pomocou Mahalanobisovej vzdialenosti

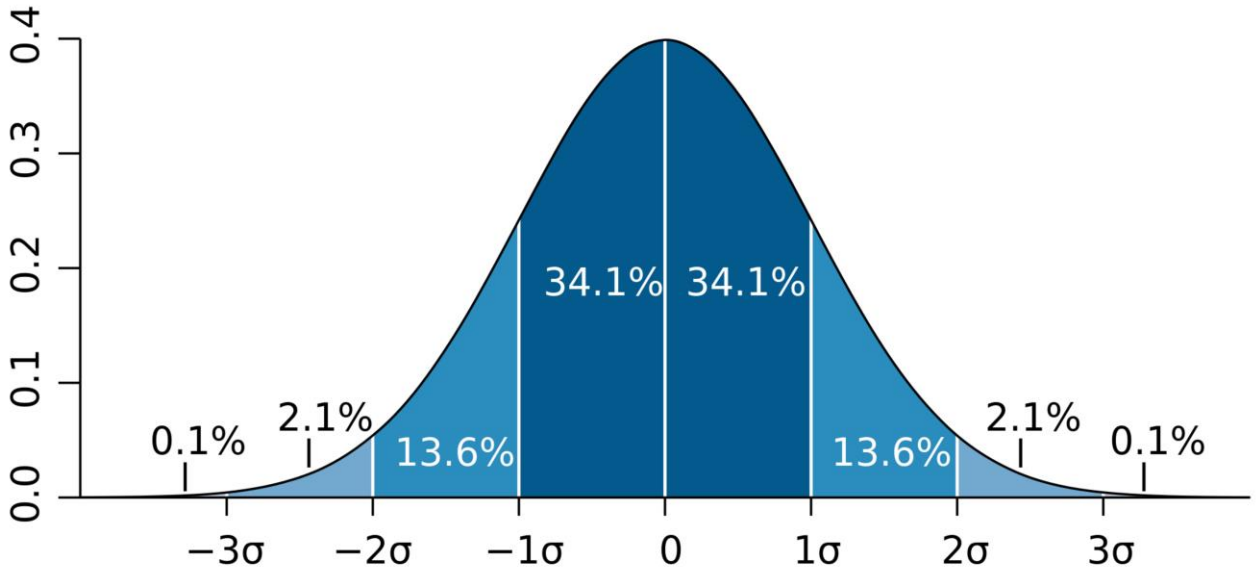

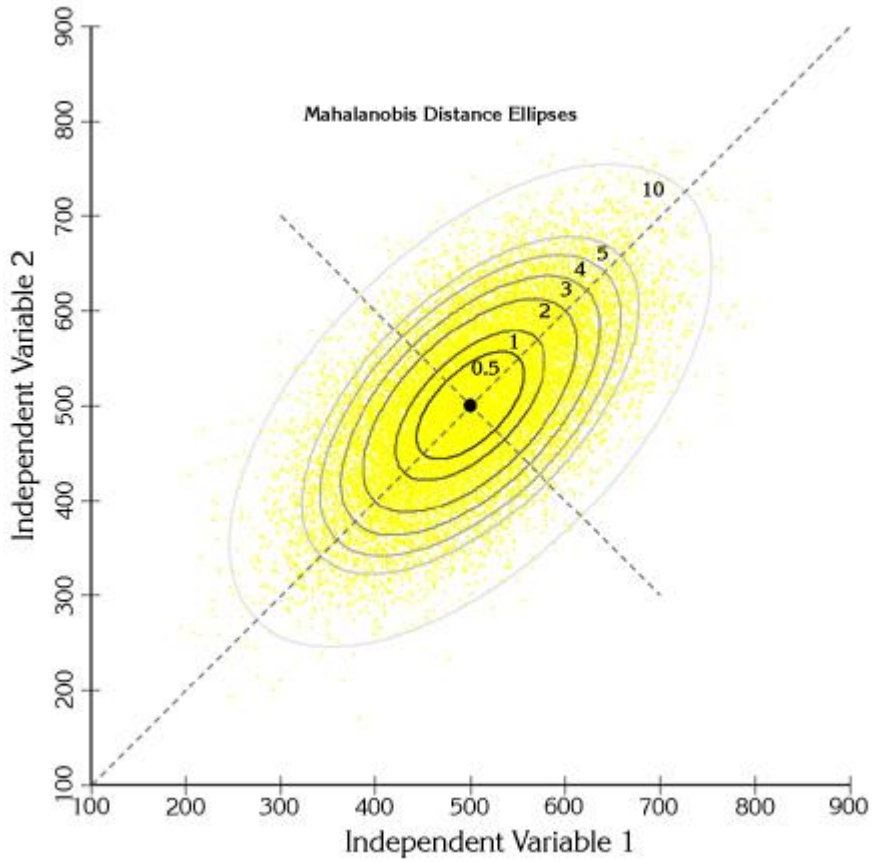

Model riešenia a základné pojmy

- Fáza č.2 – klasifikácia pomocou Mahalanobisovej vzdialenosti
  - Výpočet:

$$d(x) = \sqrt{(x - \mu_K)\ \ S^{-1}\ (x - \mu_K)^T}$$

x	testovací vektor vyjadrený PCA koeficientami
μ_K	stredná hodnota PCA koeficientov fotiek v konkrétnej triede K
S^{-1}	inverzná matica ku kovariančnej matici trénovacích vektorov v triede K (*každý trénovací vektor je vyjadrený PCA koeficientami*)

Model riešenia a základné pojmy

- Fáza č.2 – klasifikácia pomocou Mahalanobisovej vzdialenosti
  - Názorná ukážka v Matlabe (Mahalanobisova vzdialenosť x od stredu rozdelenia náhodne zvolených údajov)
  - Manuálny výpočet

```
x =

     5     9     7
```

```
train_sample =

     8     1     6
     3     5     7
     4     9     2
     8     5     2
     9     6     3
     1     4     7
```

Model riešenia a základné pojmy

- Fáza č.2 – klasifikácia pomocou Mahalanobisovej vzdialenosti

1

```
x =

     5     9     7
```

Model riešenia a základné pojmy

- Fáza č.2 – klasifikácia pomocou Mahalanobisovej vzdialenosti

1

```
x =

     5     9     7
```

2

```
train_sample =

     8     1     6
     3     5     7
     4     9     2
     8     5     2
     9     6     3
     1     4     7
```

Model riešenia a základné pojmy

- Fáza č.2 – klasifikácia pomocou Mahalanobisovej vzdialenosti

1

```
x =

     5     9     7
```

2

```
train_sample =

     8     1     6
     3     5     7
     4     9     2
     8     5     2
     9     6     3
     1     4     7
```

3

```
>> mean_value = mean(train_sample)

mean_value =

    5.5000    5.0000    4.5000
```

Model riešenia a základné pojmy

- Fáza č.2 – klasifikácia pomocou Mahalanobisovej vzdialenosti

1

```
x =

     5     9     7
```

2

```
train_sample =

     8     1     6
     3     5     7
     4     9     2
     8     5     2
     9     6     3
     1     4     7
```

3

```
>> mean_value = mean(train_sample)

mean_value =

    5.5000    5.0000    4.5000
```

4

```
>> sqrt((x-mean_value)*inv(cov(train_sample))*(x-mean_value)')

ans =

    5.6088
```

Model riešenia a základné pojmy

- Fáza č.2 – klasifikácia pomocou Mahalanobisovej vzdialenosti

1

```
x =

     5     9     7
```

2

```
train_sample =

     8     1     6
     3     5     7
     4     9     2
     8     5     2
     9     6     3
     1     4     7
```

3

```
>> mean_value = mean(train_sample)

mean_value =

    5.5000    5.0000    4.5000
```

4

```
>> sqrt((x-mean_value)*inv(cov(train_sample))*(x-mean_value)')

ans =

    5.6088
```

$$d(x) = \sqrt{(x - \mu_K)\ \ S^{-1}\,(x - \mu_K)^T}$$

Model riešenia a základné pojmy

- Fáza č.2 – klasifikácia pomocou Mahalanobisovej vzdialenosti
  - Použitie knižničnej funkcie

```
x =

     5     9     7
```

```
train_sample =

     8     1     6
     3     5     7
     4     9     2
     8     5     2
     9     6     3
     1     4     7
```

```
>> sqrt(mahal(x,train_sample))

ans =

    5.6088
```

Model riešenia a základné pojmy

- Fáza č.2 – klasifikácia pomocou Mahalanobisovej vzdialenosti
  - Stručný návod ako použiť Mahalanobisovu vzdialenosť na klasifikovanie obrazu tváre T_1:
    1. Vytvoríme PCA model z trénovacích dát
    2. Po projekcii získame PCA koeficienty tváre T_1 (napr. pomocou *project()* v OpenCV)
    3. Vypočítame Mahalanobisovu vzdialenosť PCA koeficientov tváre T_1 postupne od stredu pravdepodobnostného rozdelenia PCA koeficientov každej triedy v trénovacej množine

Model riešenia a základné pojmy

- Fáza č.2 – klasifikácia pomocou Mahalanobisovej vzdialenosti

Model riešenia a základné pojmy

- Fáza č.2 – klasifikácia pomocou Mahalanobisovej vzdialenosti

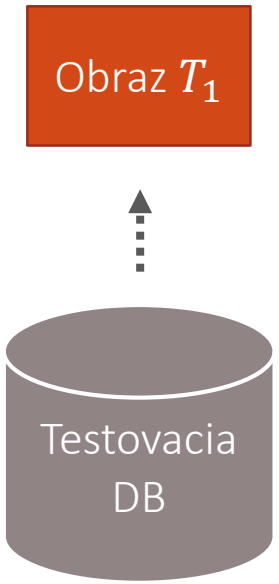

Model riešenia a základné pojmy

- Fáza č.2 – klasifikácia pomocou Mahalanobisovej vzdialenosti

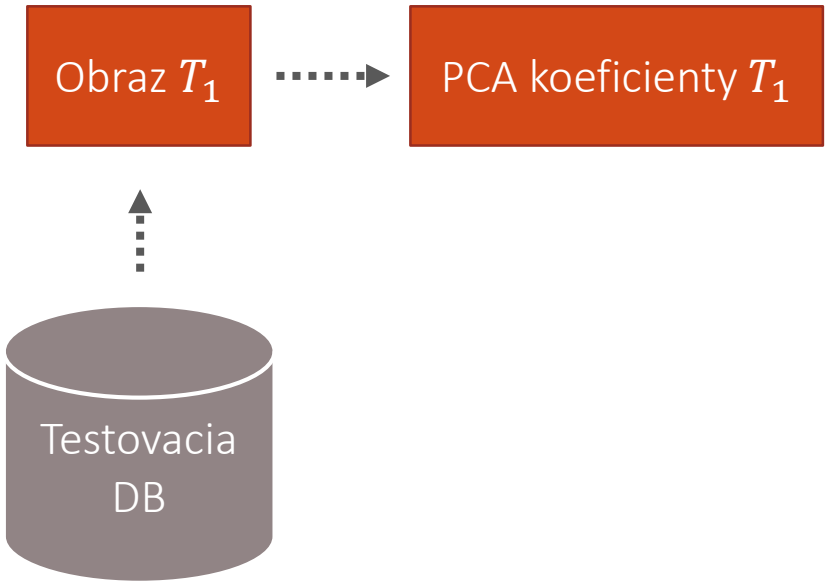

Model riešenia a základné pojmy

- Fáza č.2 – klasifikácia pomocou Mahalanobisovej vzdialenosti

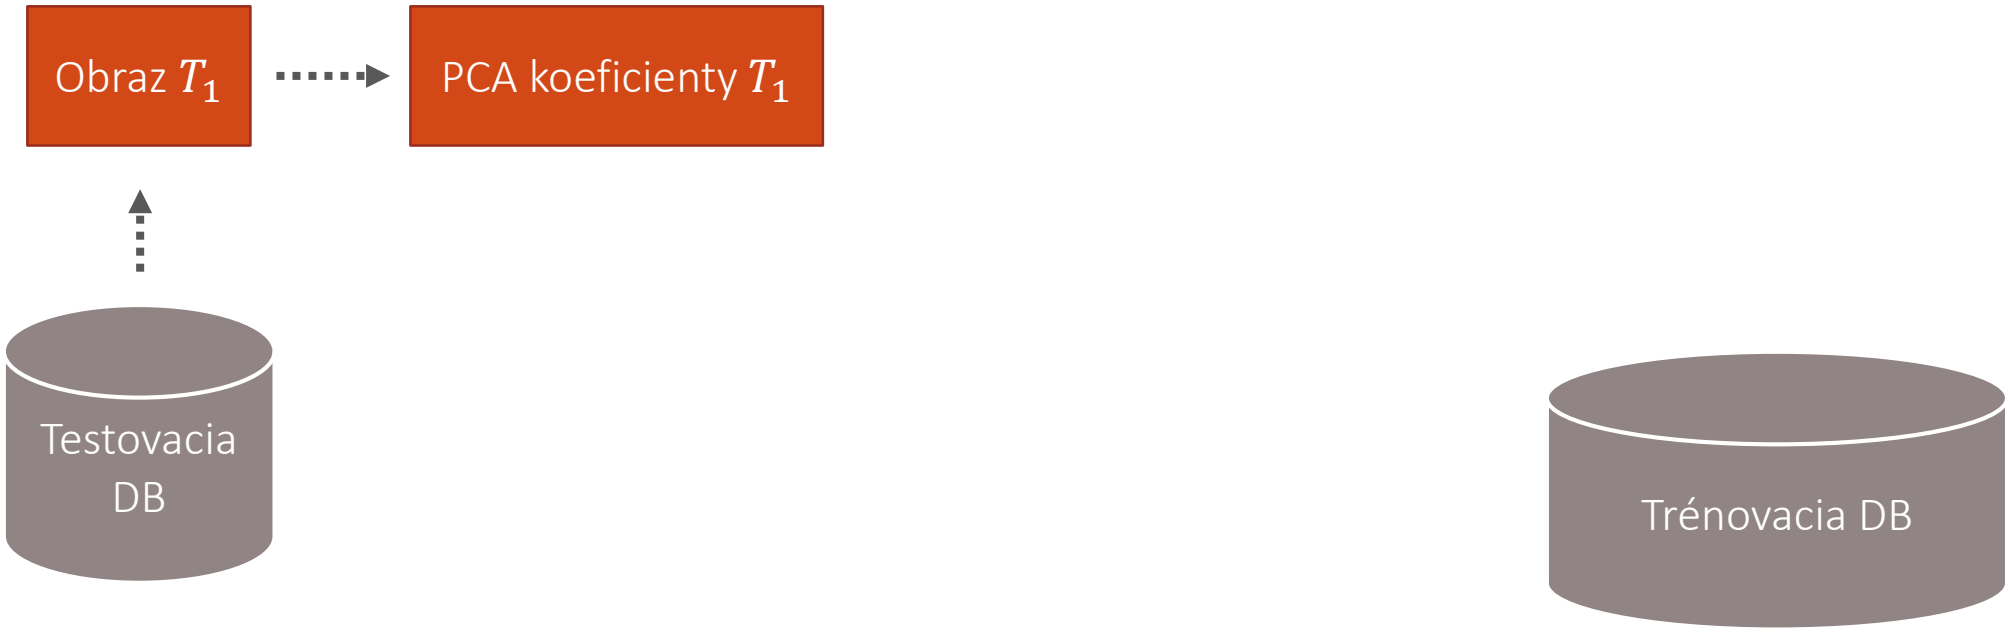

Model riešenia a základné pojmy

- Fáza č.2 – klasifikácia pomocou Mahalanobisovej vzdialenosti

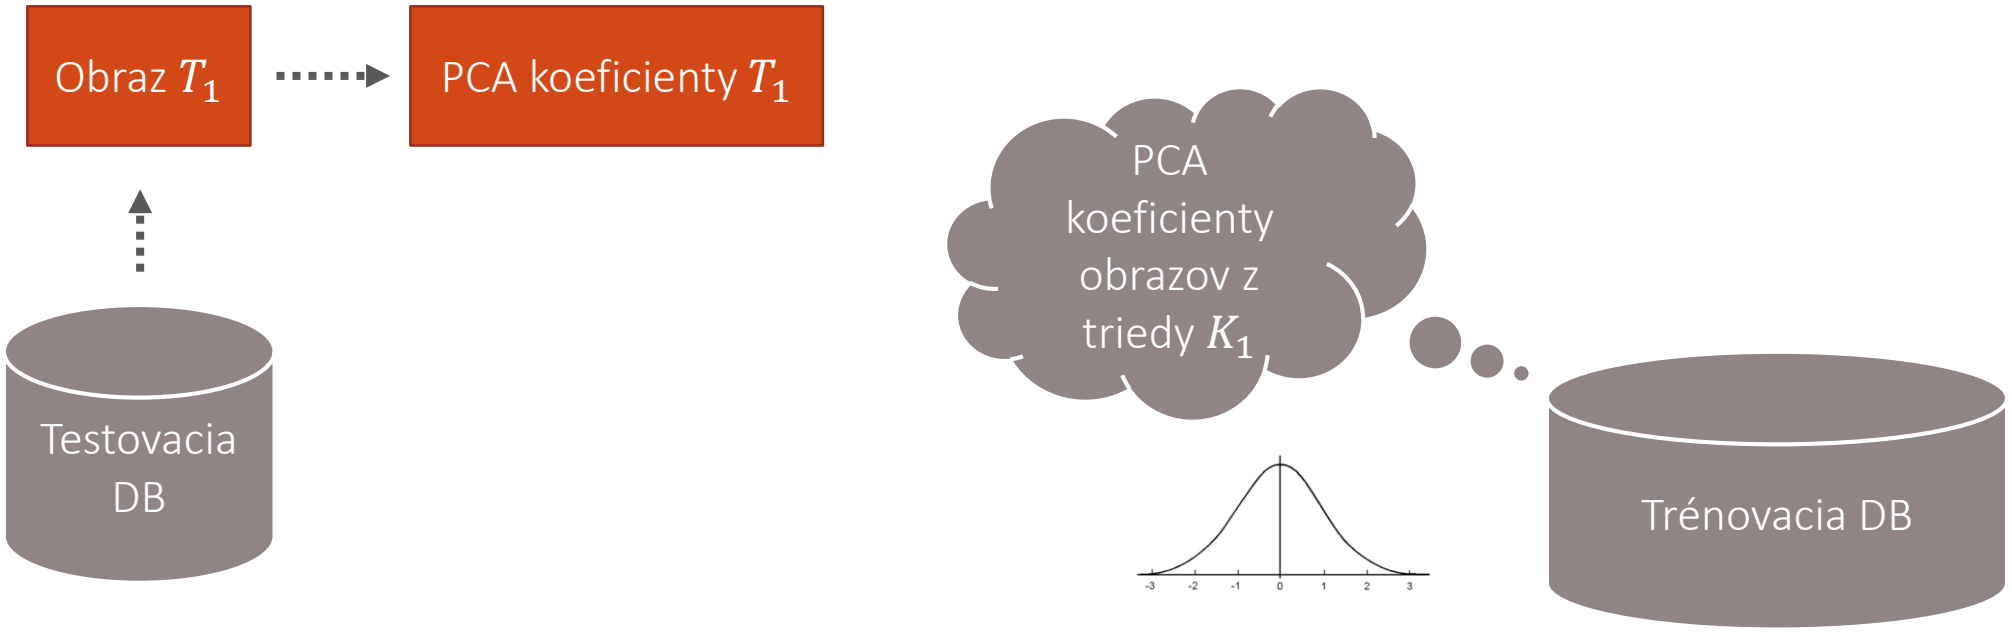

Model riešenia a základné pojmy

- Fáza č.2 – klasifikácia pomocou Mahalanobisovej vzdialenosti

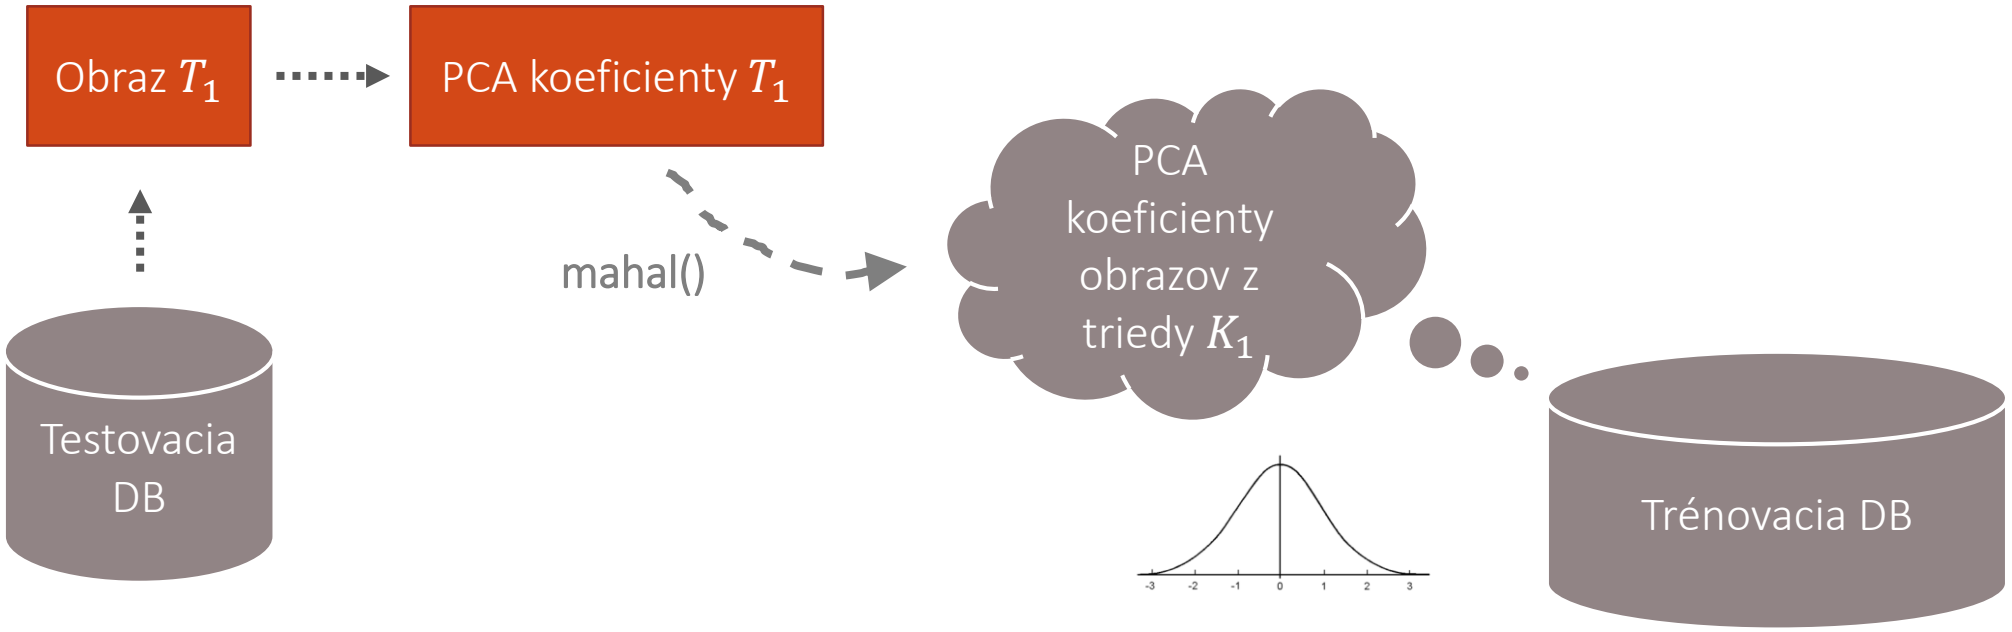

Model riešenia a základné pojmy

- Fáza č.2 – klasifikácia pomocou Mahalanobisovej vzdialenosti

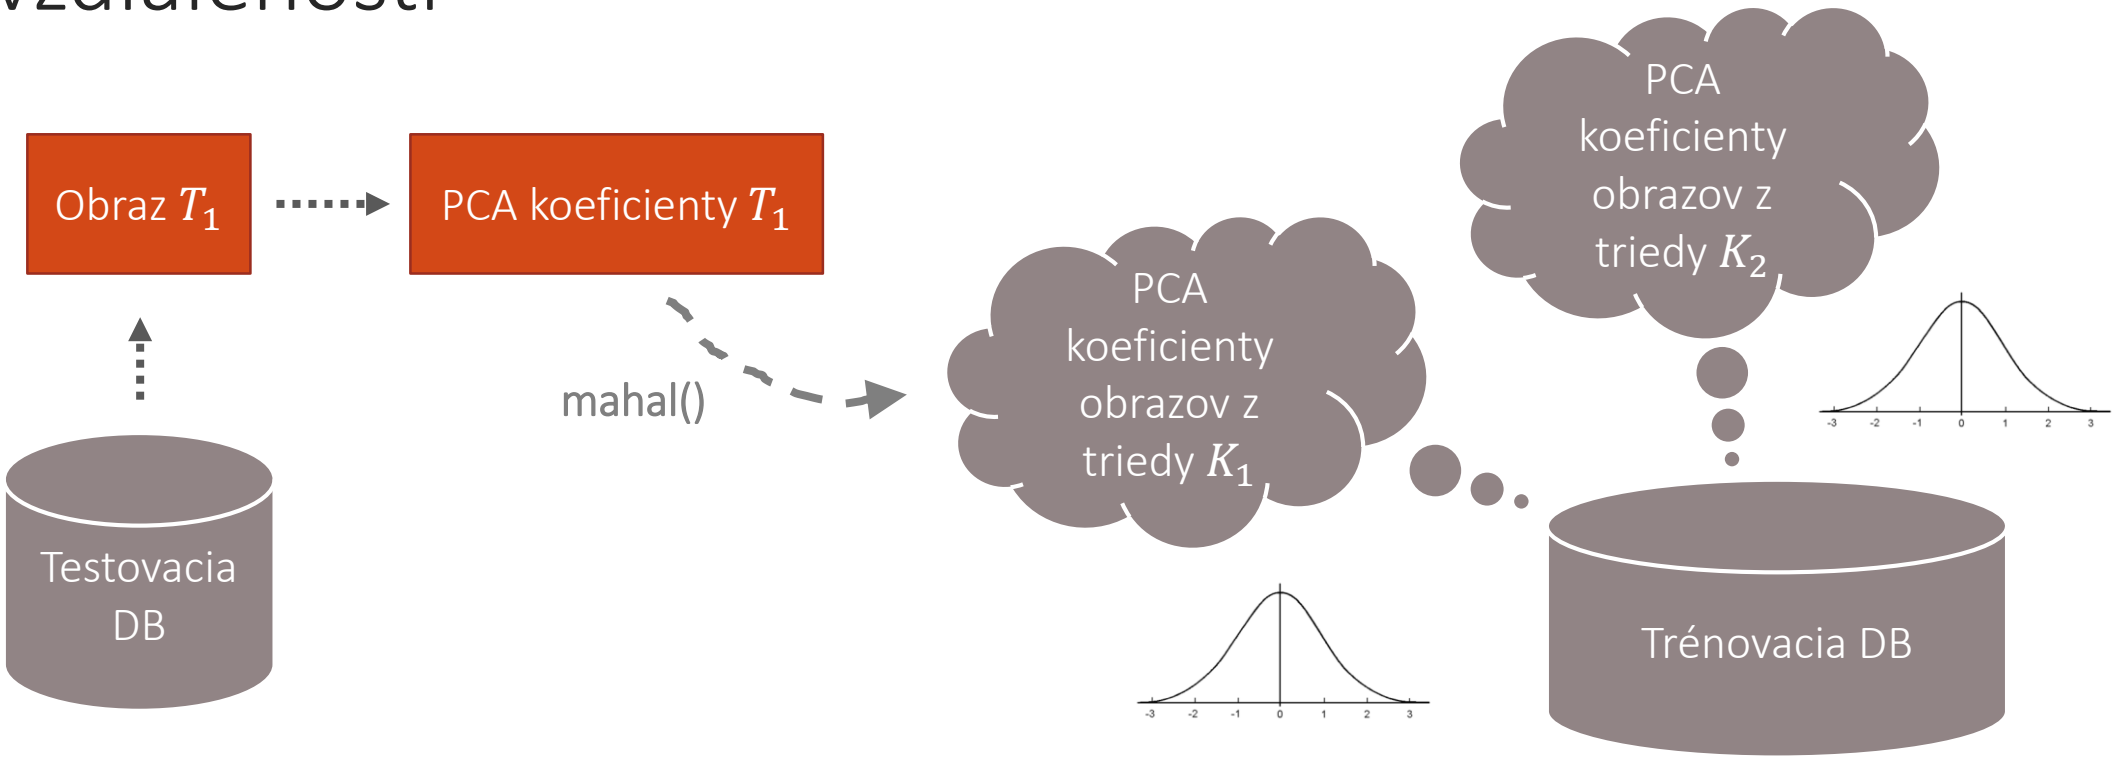

Model riešenia a základné pojmy

- Fáza č.2 – klasifikácia pomocou Mahalanobisovej vzdialenosti

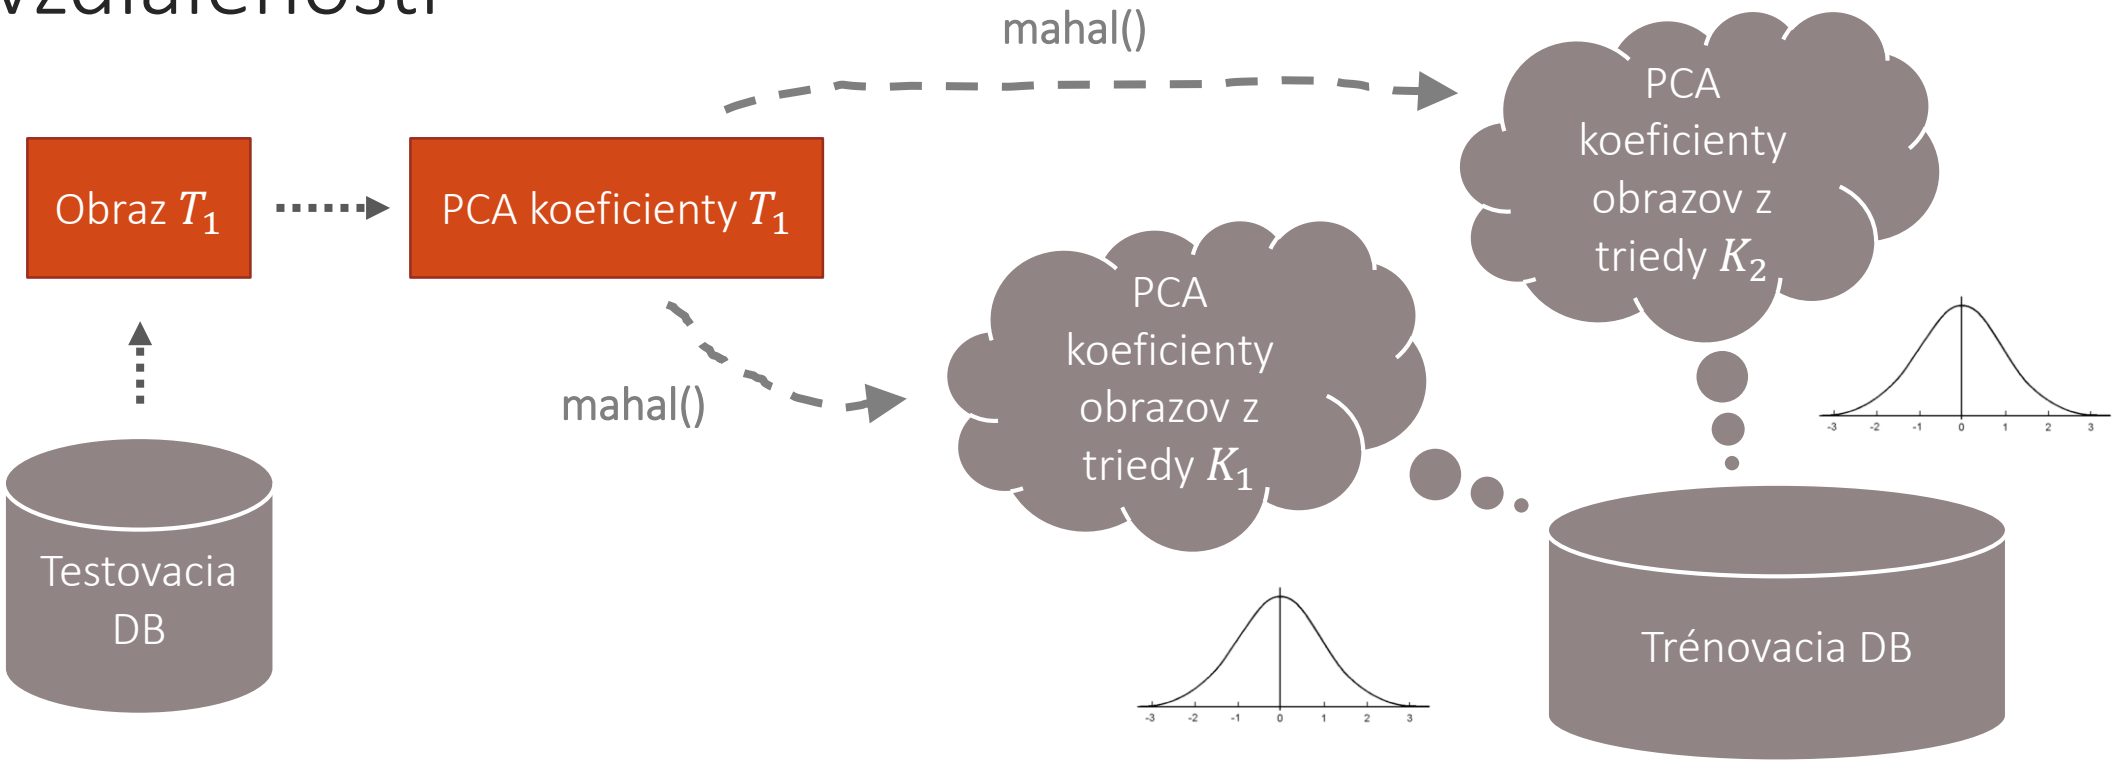

Model riešenia a základné pojmy

- Fáza č.2 – klasifikácia pomocou Mahalanobisovej vzdialenosti

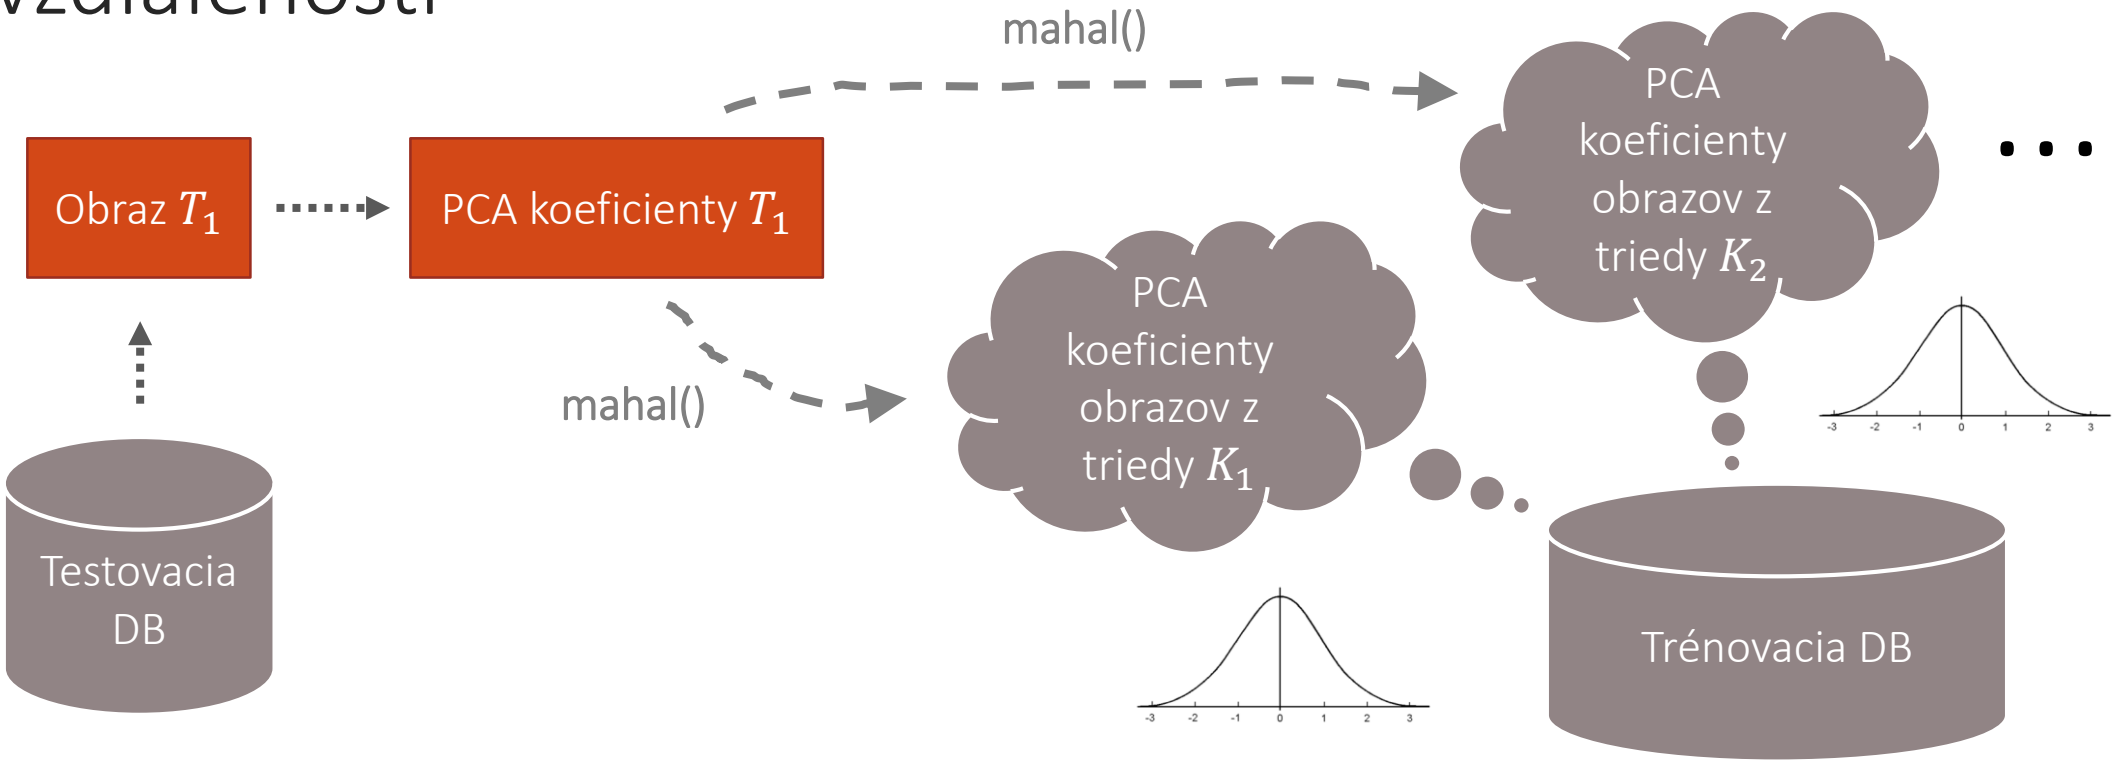

Model riešenia a základné pojmy

- Sumarizácia

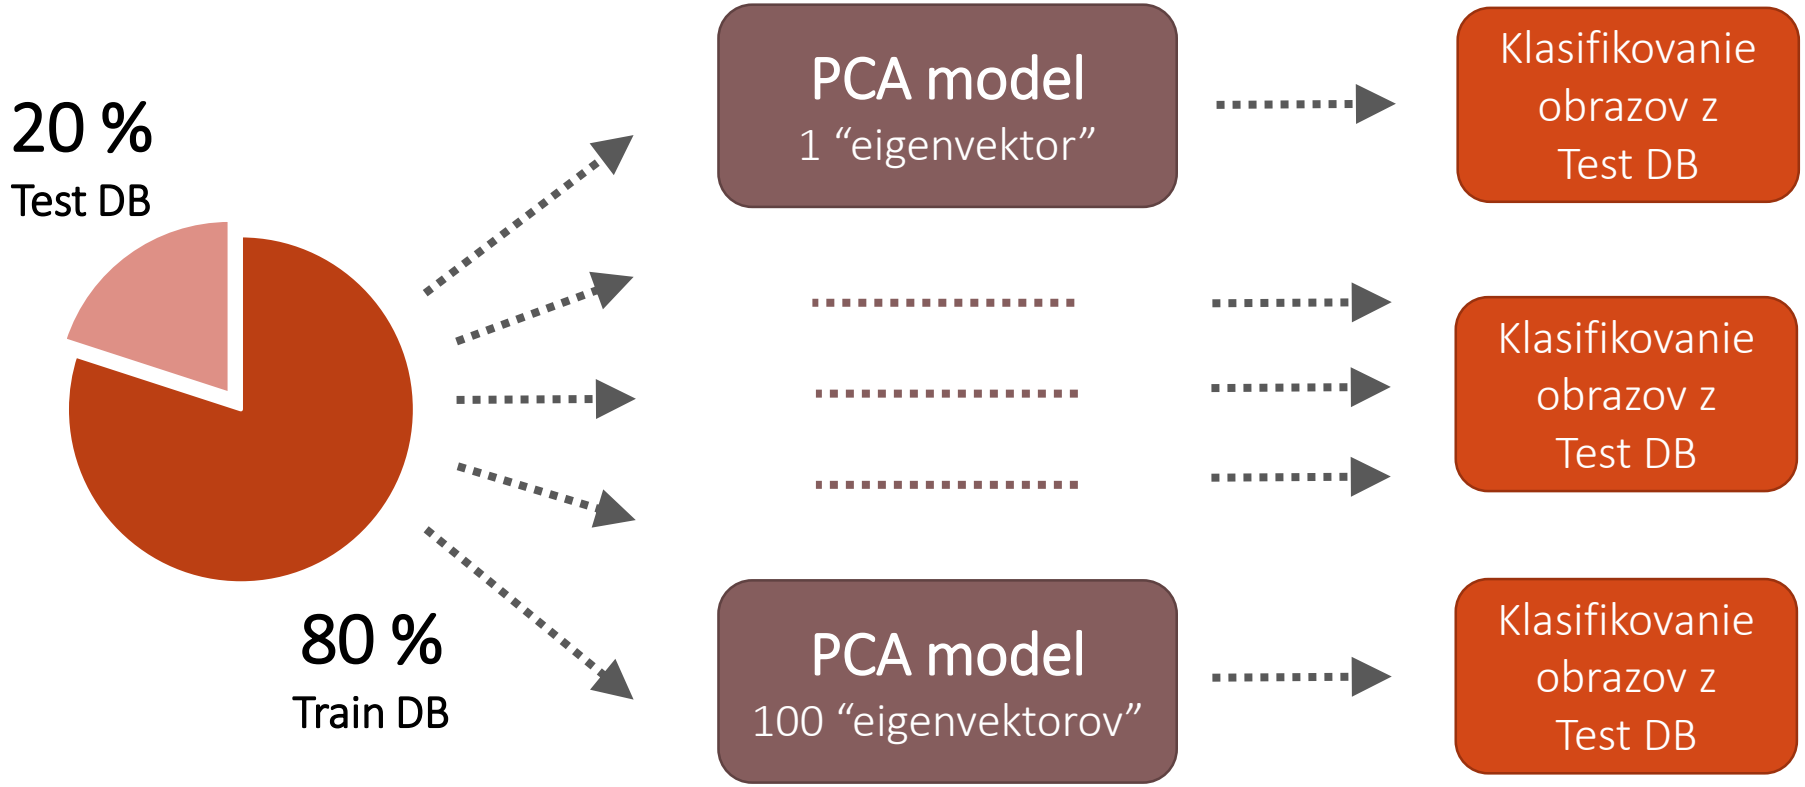

Model riešenia a základné pojmy

- Výstupný graf
  - Databáza A
  - TrainSize = 8
  - TestSize = 2

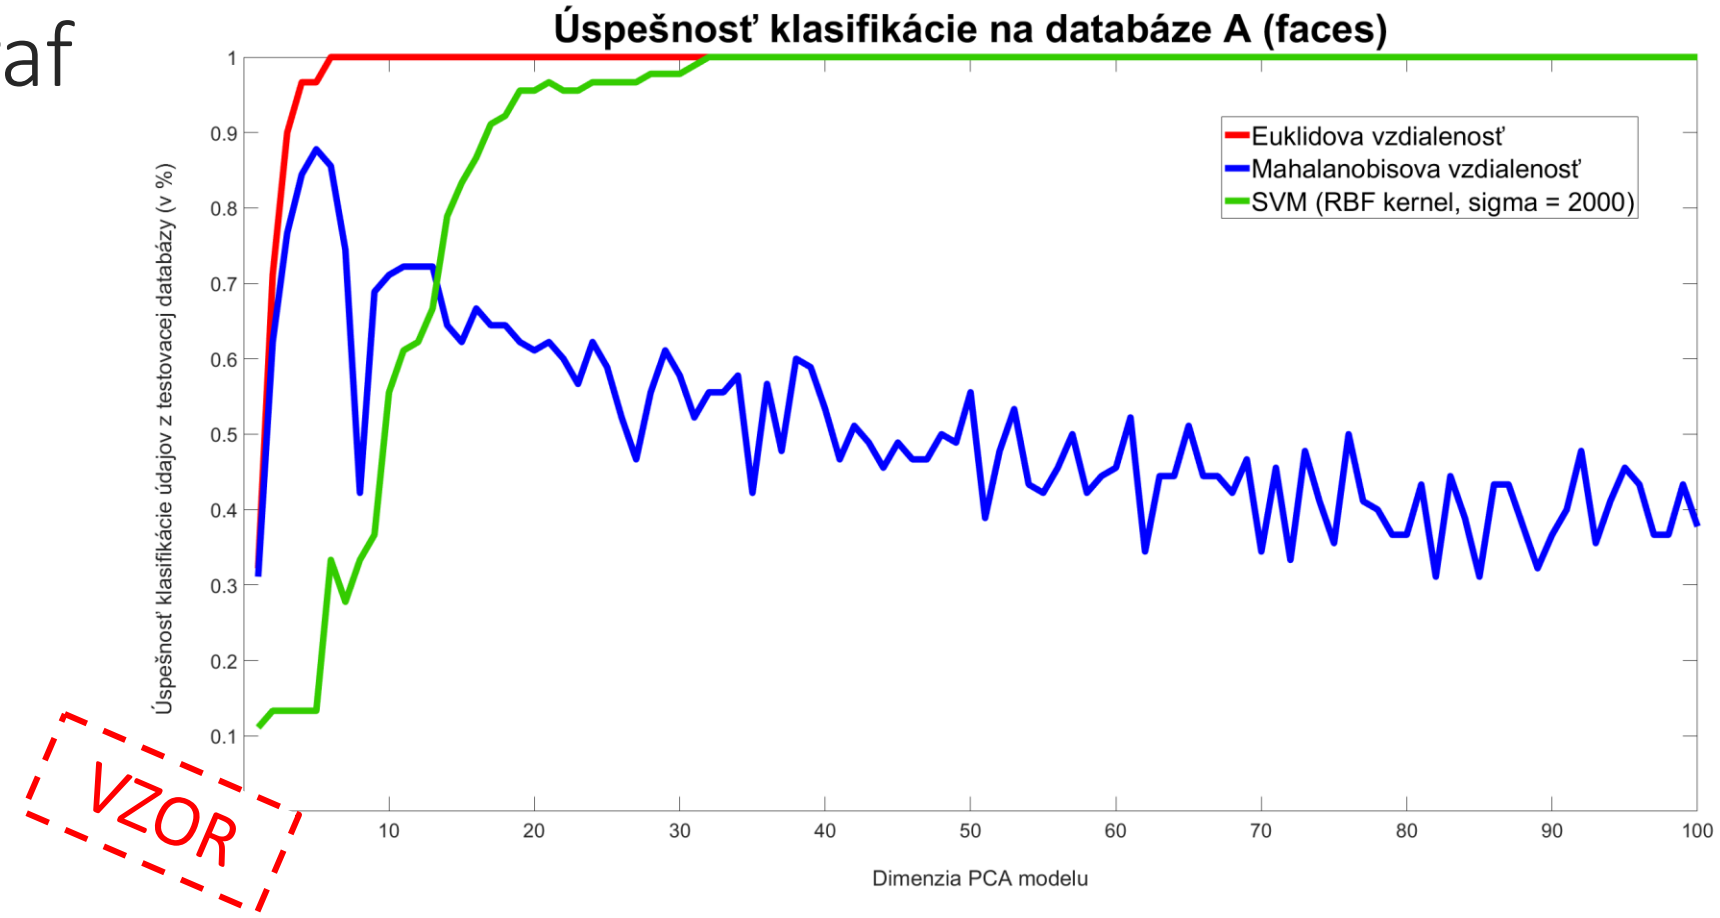

Model riešenia a základné pojmy

- Výstupný graf
  - Databáza B
  - TrainSize = 10
  - TestSize = 2

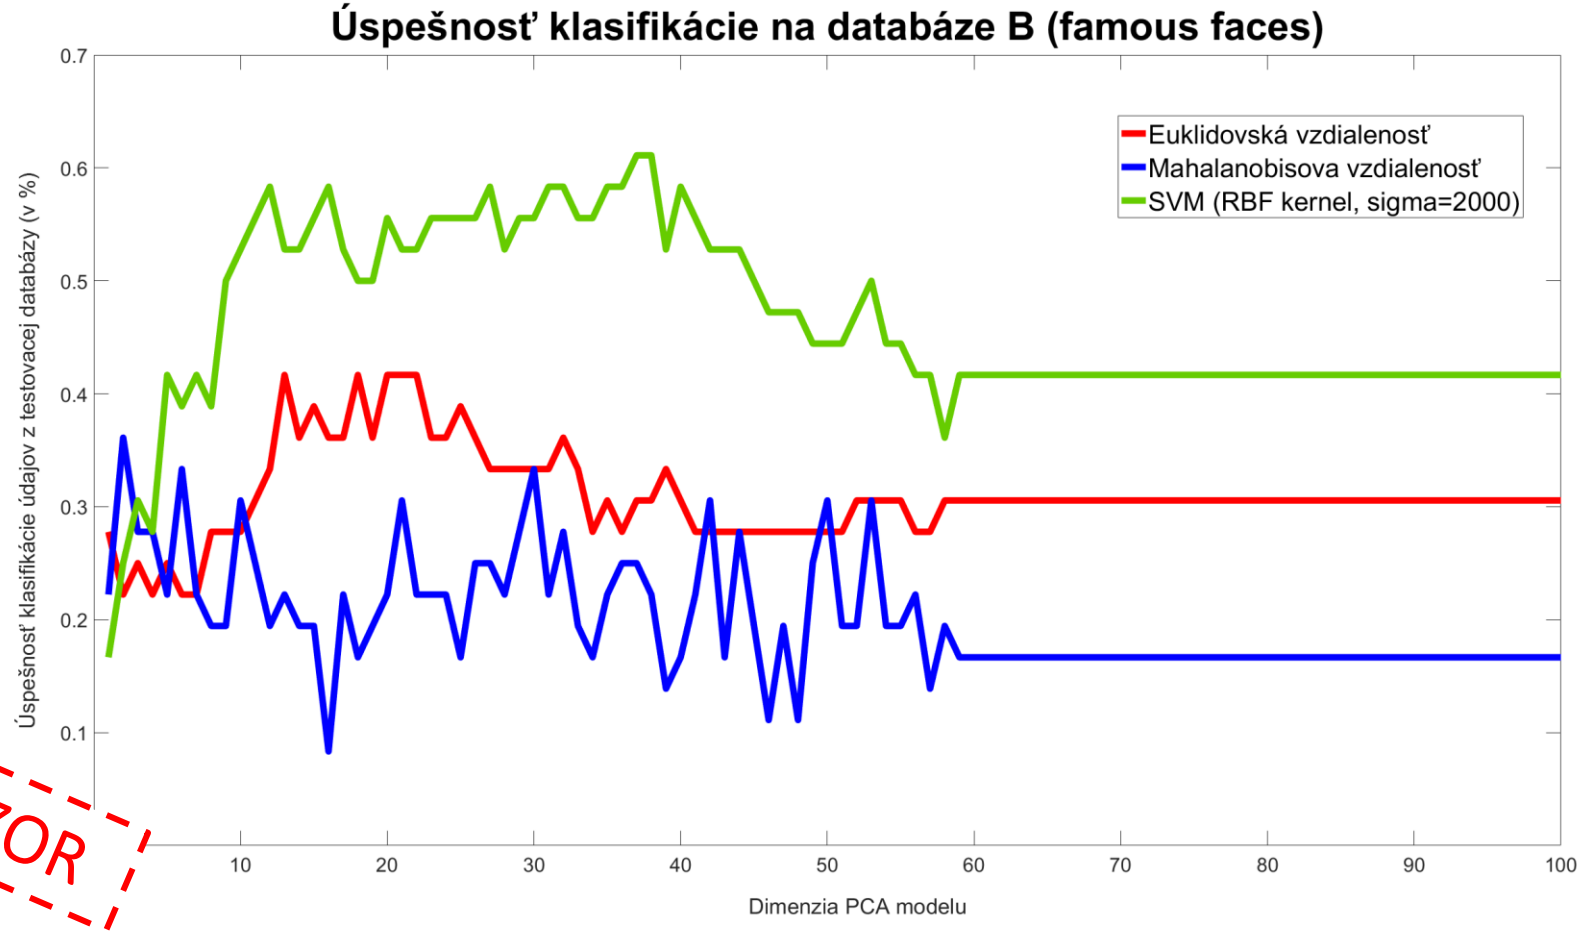

VZOR

Bodovanie

Použitá cross-validácia	1b
Správne použitie PCA metódy	1b
Odprezentovanie použitých klasifikátorov:	
• SVM	1b
• Euklidova vzdialenosť	1b
• Mahalanobisova vzdialenosť	3b
Graf úspešnosti klasifikátorov	3b
Spolu	10b